

Análisis de la multicolinealidad inducida por interacciones en modelos lineales

XXXIX International Conference ASEPELT, June 24-27 2026

Román Salmerón y Catalina García

romansg@ugr.es

cbgarcia@ugr.es

Departamento de Métodos Cuantitativos para la Economía y la Empresa
Universidad de Granada

<https://github.com/rnoremlas/documentos>

25 junio 2026



Apartado 1. Introducción



Preliminares

La inclusión de interacciones en el modelo de regresión lineal múltiple es muy habitual en la literatura cuantitativa en las Ciencias Sociales, Económicas y Jurídicas ya que es frecuente que la relación entre variables dependa de los valores de una tercera.

Ahora bien, tal y como se recoge en el trabajo de Brambor, Clark y Golder (2006), la aplicación de estos modelos suele ser defectuosa, por lo que conduce a análisis erróneos. En este artículo se establecen las bases que permiten mejorar los análisis empíricos en este tipo de modelos.

4.817 citas recibidas según WoS a 25/04/2026

Brambor, T., Clark, W.R. y Golder, M. (2006). Understanding interaction models: improving empirical analyses. *Political Analysis*, 14(1), doi: <https://doi.org/10.1093/pan/mpi014>.

En lo que respecta al **problema de multicolinealidad aproximada**, Brambor, Clark y Golder indican que **este problema se ha exagerado en los modelos de interacción** y que **no es cierto que centrar las variables relevantes pueda mitigar** cualquier problema de multicolinealidad que pudiera existir en este tipo de modelos.

Preliminares

Sin embargo, el Trabajo Fin de Máster (TFM) titulado “El problema de la multicolinealidad en modelos de regresión con interacciones: análisis de las tasas de suicidio en España” pone de manifiesto (en un caso de estudio) que **el centrado de la variable que provoca el problema** preexistente a la inclusión de la interacción **es la forma más eficaz de resolver el problema** detectado.

Trabajo Fin de Máster

Rodríguez, P. (2026). El problema de la multicolinealidad en modelos de regresión con interacciones: análisis de las tasas de suicidio en España. TFM tutorizado por Salmerón, R., url: <https://hdl.handle.net/10481/109726>.

Estas conclusiones refutaría la afirmación de Brambor, Clark y Golder sobre que *los investigadores deberían dejar de justificar el centrado de variables en los modelos de interacción porque esto reduce el grado de multicolinealidad existente en el modelo*.

Preliminares

Antes de continuar, es conveniente conocer lo siguiente:

Multicolinealidad aproximada de tipo no esencial: Relaciones lineales aproximadas entre el término independiente del modelo de regresión lineal y al menos una de las restantes variables independientes.

Multicolinealidad aproximada de tipo esencial: Relaciones lineales aproximadas entre al menos dos de las variables independientes del modelo excluido el término independiente.

- La multicolinealidad de tipo esencial se puede detectar mediante el coeficiente de variación (CV) o el número de condición (NC).
- El factor de inflación de la varianza (FIV) sólo detecta la multicolinealidad de tipo esencial, o lo que es lo mismo, ignora la de tipo no esencial.
- Para ver el papel del término independiente puede ser útil calcular el NC teniendo en cuenta (o no) el término independiente.

Objetivo

El principal objetivo es **analizar cuándo la inclusión de un término de interacción en un modelo lineal aumenta la multicolinealidad**.

Concretamente, se ilustrará que...

- **(H1)** Aunque la interacción no es combinación lineal de las variables originales, puede elevar la multicolinealidad de forma relevante si ya existe un problema grave de tipo **no esencial** ligado a alguna de las variables que forman la interacción. En ese caso, centrar variables es eficaz para mitigar el problema.
- **(H2)** Si la multicolinealidad previa entre las variables que forman la interacción es **esencial**, la interacción no la incrementa sustancialmente y el centrado no es útil; deben emplearse técnicas alternativas como regresión cresta, Lasso,alzada o residualizada.

Así, se clarifica la literatura existente sobre el tema matizando la afirmación de Brambor, Clark y Golder (2006) y **se establece un criterio objetivo sobre cuándo el centrado es realmente útil** para mitigar el problema de multicolinealidad.

Apartado 2. El modelo



El modelo de interacciones

Para abordar los objetivos anteriores se considerará, sin pérdida de generalidad, el modelo de regresión lineal múltiple con interacciones más sencillo posible. Este modelo estará formado por el término independiente, dos variables independientes más y la interacción de éstas.

Ahora bien, este modelo puede presentar distintas versiones dependiendo de la naturaleza de las dos variables independientes consideradas. Así, es posible que ambas sean binarias, una binaria y otra continua y, por último, ambas continuas.

En este caso se abordará el modelo de interacción en el que las variables independientes son el término independiente, una variable binaria, **D**, y otra continua, **Z**, esto es:

$$\mathbf{y} = \beta_1 + \beta_2 \cdot \mathbf{D} + \beta_3 \cdot \mathbf{Z} + \beta_4 \cdot \mathbf{D} \times \mathbf{Z} + \mathbf{u}.$$

El resto de casos se abordarán en un futuro

Intuición

El conjunto de variables independientes del modelo está formado por $\{1, \mathbf{D}, \mathbf{Z}, \mathbf{D} \times \mathbf{Z}\}$, donde 1 denota al término independiente.

- Si se excluye el término de interacción, $\{1, \mathbf{D}, \mathbf{Z}\}$, las posibles relaciones lineales pueden ser de tipo no esencial (relación de $\mathbf{D}$ o $\mathbf{Z}$ con el término independiente) o esencial (relación de $\mathbf{D}$ con $\mathbf{Z}$).
- Para que $\mathbf{D}$ esté altamente relacionada con el término independiente es claro que la proporción de unos que debe de contener la variable binaria ha de ser muy alta.
- Igual ocurre para que $\mathbf{D}$ se relacione linealmente con $\mathbf{Z}$ (H2).
- Descartando estas posibilidades en modelos con datos reales, la opción más plausible para que exista un grado de multicolinealidad alta en este caso es que la variable $\mathbf{Z}$ sea responsable de un problema de **multicolinealidad no esencial** (H1), es decir, se ha de verificar que $\mathbf{Z} \approx a \cdot 1$, siendo a una constante.
- En este caso, el conjunto de variables independientes del modelo de interacción es de la forma $\{1, \mathbf{D}, a \cdot 1, \mathbf{D} \times a\}$, donde ya se observa que la variable $\mathbf{D}$ está relacionada linealmente (es proporcional) con la interacción añadida, dando lugar a una relación de tipo **esencial**.

Apartado 3. Simulación



Simulación de Monte Carlo

Se plantea simular datos para el modelo $\mathbf{y} = \beta_1 + \beta_2 \cdot \mathbf{D} + \beta_3 \cdot \mathbf{Z} + \beta_4 \cdot \mathbf{D} \times \mathbf{Z} + \mathbf{u}$ donde:

- $\mathbf{D} \sim B(n, p)$ donde $n \in \{20, 25, \dots, 195, 200\}$ y $p \in \{0.3, 0.4, 0.5, 0.6, 0.7\}$ y
- $\mathbf{Z} \sim N(5, \sigma^2)$ con $\sigma \in \{0.01, 0.02, \dots, 0.09, 0.1, 0.2, \dots, 0.9, 1, 1.5, 2, 2.5, \dots, 8, 8.5, 9\}$.

La combinación anterior supone 6475 iteraciones, donde se calcula el CV de $\mathbf{Z}$, el FIV de $\mathbf{Z}$ y $\mathbf{D} \times \mathbf{Z}$ (el de $\mathbf{D}$ no tiene sentido calcularlo) y el NC de $\{\mathbf{D}, \mathbf{Z}, \mathbf{D} \times \mathbf{Z}\}$ (sin tener presente la constante) y $\{\mathbf{1}, \mathbf{D}, \mathbf{Z}, \mathbf{D} \times \mathbf{Z}\}$ (teniendo presente la constante). Se plantean entonces dos situaciones:

- El coeficiente de variación de $\mathbf{Z}$ es menor que 0.1, de forma que hay multicolinealidad de tipo no esencial preocupante (ver, para más detalles, Salmerón et al. (2020)).
- El coeficiente de variación de $\mathbf{Z}$ es mayor que 0.1, de forma que la multicolinealidad de tipo no esencial existente no es preocupante.

Salmerón, R., Rodríguez, A. y García, C.B. (2020). Diagnosis and quantification of the non-essential collinearity. Computational Statistics, 35(2), 647-666, doi: <https://doi.org/10.1007/s00180-019-00922-x>.

Simulación de Monte Carlo

Si el coeficiente de variación de Z es menor que 0.1

- La media del NC en las iteraciones sin tener presente al término independiente es igual a 267'77, lo cual indica **multicolinealidad esencial preocupante**.
- La media del FIV en las iteraciones de Z es igual a 2'48 y el de $D \times Z$ es igual a 31925'09, lo cual indica que **el grado preocupante de multicolinealidad esencial detectado se debe a la interacción**.
- La media del NC en las iteraciones teniendo presente al término independiente es igual a 599'12, lo cual indica que el **término independiente incrementa sustancialmente el grado de multicolinealidad existente**.

Los puntos anteriores indican que **si existe previamente un problema grave de tipo no esencial ligado a la variable cuantitativa que forma la interacción, la interacción eleva el grado de multicolinealidad existente ya que es responsable de un problema de multicolinealidad esencial**.

Simulación de Monte Carlo

Si el coeficiente de variación de Z es mayor que 0.1

- La media del NC en las iteraciones sin tener presente al término independiente es igual a 7'09, lo cual indica que la **multicolinealidad esencial existente no es preocupante**.
- La media del NC en las iteraciones teniendo presente al término independiente es igual a 14'89, lo cual indica que el **término independiente NO incrementa sustancialmente el grado de multicolinealidad existente**.

Los puntos anteriores indican que **si NO existe previamente un problema grave de tipo no esencial ligado a la variable cuantitativa que forma la interacción, la interacción NO eleva el grado de multicolinealidad existente, NO siendo responsable de un problema de multicolinealidad esencial**.

Un ejemplo de lo que estamos hablando

Obs.	ts	tp	m	tp $\times$ m
Andalucía	9.71	1	50.74	50.74
Aragón	8.54	0	50.58	0
Asturias	12.53	0	52.31	0
Islas Baleares	9.10	1	50.22	50.22
Canarias	10.59	1	50.62	50.62
Cantabria	10.05	0	51.53	0
Castilla y León	10.11	0	50.78	0
Castilla La Mancha	8.88	1	49.93	49.93
Cataluña	7.84	0	50.80	0
Comunidad Valenciana	8.62	0	50.77	0
Extremadura	9.00	1	50.56	50.56
Galicia	12.17	0	51.88	0
Comunidad de Madrid	5.92	0	52.15	0
Región de Murcia	8.89	0	49.90	0
Navarra	8.53	0	50.52	0
País Vasco	7.87	0	51.38	0
Rioja	9.35	0	50.65	0
Ceuta	2.41	1	49.54	49.54
Melilla	1.17	1	49.54	49.54

Datos usados en el TFM sobre la tasa de suicidio en España para el año 2022: se observa que la poca variabilidad de la variable m hace que exista relación lineal entre la variable tp y la interacción.

Se verifica la primera parte de H1: aunque la interacción no es combinación lineal de las variables originales, puede elevar la multicolinealidad de forma relevante si ya existe un problema grave de tipo no esencial ligado a alguna de las variables que forman la interacción.

Simulación de Monte Carlo

Se plantea simular datos para el modelo $\mathbf{y} = \beta_1 + \beta_2 \cdot \mathbf{D} + \beta_3 \cdot \mathbf{Z}_c + \beta_4 \cdot \mathbf{D} \times \mathbf{Z} + \mathbf{u}$ donde:

- $\mathbf{D} \sim B(n, p)$ donde $n \in \{20, 25, \dots, 195, 200\}$ y $p \in \{0.3, 0.4, 0.5, 0.6, 0.7\}$ y
- $\mathbf{Z}_c = \mathbf{Z} - \bar{\mathbf{Z}}$ con $\mathbf{Z} \sim N(5, \sigma^2)$ y $\sigma \in \{0.01, 0.02, \dots, 0.09, 0.1, 0.2, \dots, 0.9, 1, 1.5, 2, 2.5, \dots, 8, 8.5, 9\}$.

Es decir, se plantea exactamente la misma simulación con la salvedad de que se centra la variable cuantitativa.

- En este caso, el mínimo CV de $\mathbf{Z}$ es igual a $1'906 \cdot 10^{13}$ (debería ser infinito).
- La media del NC en las iteraciones sin tener presente al término independiente es igual a 2'604, lo cual indica que la **multicolinealidad esencial existente no es preocupante**.
- La media del NC en las iteraciones teniendo presente al término independiente es igual a 2'84, lo cual indica que **el término independiente no tiene un papel relevante**.
- La media del FIV en las iteraciones de $\mathbf{Z}$ es igual a 2'443 y el de $\mathbf{D} \times \mathbf{Z}$ es igual a 2'427, lo cual indica que **el grado de multicolinealidad esencial detectado no es preocupante**.

Un ejemplo de lo que estamos hablando

Obs.	ts	tp	m _c	tp × m _c
Andalucía	9.71	1	-0.02	-0.02
Aragón	8.54	0	-0.18	0
Asturias	12.53	0	1.55	0
Islas Baleares	9.10	1	-0.54	-0.54
Canarias	10.59	1	-0.14	-0.14
Cantabria	10.05	0	0.77	0
Castilla y León	10.11	0	0.02	0
Castilla La Mancha	8.88	1	-0.83	-0.83
Cataluña	7.84	0	0.04	0
Comunidad Valenciana	8.62	0	0.01	0
Extremadura	9.00	1	-0.20	-0.20
Galicia	12.17	0	1.12	0
Comunidad de Madrid	5.92	0	1.39	0
Región de Murcia	8.89	0	-0.86	0
Navarra	8.53	0	-0.24	0
País Vasco	7.87	0	0.62	0
Rioja	9.35	0	-0.11	0
Ceuta	2.41	1	-1.22	-1.22
Melilla	1.17	1	-1.22	-1.22

Datos usados en el TFM sobre la tasa de suicidio en España para el año 2022: se observa que salvar la poca variabilidad de la variable m (centrándola) hace que no exista relación lineal entre la variable tp y la interacción.

En definitiva, el centrado de la variable que provoca el problema es eficaz para mitigar el problema, es decir, **se verifica la segunda parte de H1**.

Apartado 4. Conclusiones



Conclusiones

- Existe controversia sobre si centrar variables en el modelo de interacción es útil para mitigar el problema de multicolinealidad.
- En el modelo de interacciones en el que una variable es discreta y otra continua se verifica **H1**:
 - **La interacción aumenta de forma relevante el grado de multicolinealidad existente si previamente la variable cuantitativa es responsable de un problema de multicolinealidad no esencial** (ya que la no esencial induce esencial).
 - Si previamente no hay un grado de multicolinealidad no esencial preocupante, el término de interacción no aumenta de forma relevante el grado de multicolinealidad existente (como era de esperar al no ser la interacción una combinación lineal de las variables existentes).
 - Se comprueba que **mitigar el problema de multicolinealidad no esencial (centrando la variable que provoca el problema), mitiga también el problema de multicolinealidad esencial** existente al introducir la interacción.
- En el modelo de interacciones considerado no tiene sentido la existencia previa de multicolinealidad esencial entre las variables que forman la interacción, por lo que para analizar **H2** será necesario un modelo de interacciones donde ambas variables sean continuas.

Análisis de la multicolinealidad inducida por interacciones en modelos lineales

XXXIX International Conference ASEPELT, June 24-27 2026

Román Salmerón y Catalina García

romansg@ugr.es

cbgarcia@ugr.es

Departamento de Métodos Cuantitativos para la Economía y la Empresa
Universidad de Granada

<https://github.com/rnoremlas/documentos>

25 junio 2026